

综合实验课程大作业

指导教师：刘哲理 作业设计：施君鉴

第一部分 题目介绍

大作业题目：在 Ubuntu18.04 环境下，在矩阵元开源安全多方计算框架 rosetta 之上，使用多线程模拟实现分布式数据库隐私集合交集的 SQL 查询系统。

大作业要求：

- (1) 学生需要在 rosetta 安全多方计算框架之上，使用框架提供的安全算子接口，根据代码框架和注释，完成相应的开发任务；
- (2) 作业需要完成两个主要模块的开发与整合，隐私集合求交（PSI）的开发和简单 SQL 查询语句解析与 MPC 计算；
- (3) 作业不需要学生使用多台主机进行通信，只需要使用多进程模拟参与方通信交互即可，多线程代码框架和配置文件都已经给出。
- (4) 团队合作完成：同学们可以自由组队，至少 2~3 人一组完成即可。

第二部分 开发步骤

2.1 Rosetta 框架的安装

本次作业给同学们提供两种 Rosetta 安装方式，按照自己的安装情况和偏好选择即可：

(1) 同学们可以直接从 github 官网上进行 clone 并安装，Rosetta 框架的开源地址是：<https://github.com/LatticeX-Foundation/Rosetta>。使用此种方式的同学请注意，安装时根据 [readme.md](#) 文件仔细检查各种相关包的环境，否则可能会存在错误，如果无法安装或者安装受阻，请选择第二种安装方式。

(2) 使用 anaconda 直接导入 Rosetta，这里提供了已经配置好的 anaconda 环境，需要选择此种安装方式的学生自行下载。

链接：https://pan.baidu.com/s/1PYq3L9e2J75RxZDln8Ey_A 提取码：jca9

2.2 隐私集合求交模块开发

隐私集合求交技术（Private Set Intersection, PSI），是安全多方计算领域的一个重要技术。PSI 是指参与双方在不泄露任何额外信息的情况下，得到双方持有数据的交集。在这里，

额外的信息指的是除了双方的数据交集以外的任何信息。

本次作业中，同学们需要实现一个简单的 PSI 模块，旨在根据数据集中共有的属性，将三个参与方的数据集先进行隐私集合求交得到密文状态的交集，然后再将交集数据的各项记录的属性进行拼合，得到交集密文表。比如表 A(ID, NAME, AGE)和表 B(ID, DEPOSIT)可以根据相同属性ID 进行隐私集合求交，然后在交集之上，合并整个密文表为C(ID, NAME, AGE, DEPOSIT)。整个 PSI 模块的开发步骤可以参考如下过程：

第一步，两方（比如 P0、P1）参与方分别上传各自数据集，调用 Rosetta 提供的接口，生成表的秘密共享形式（密文表），这些秘密份额分别在三个计算方上进行存储；

第二步，三方在得到相应的密文表秘密共享形式之后，调用 Rosetta 提供的接口，进行 ID 属性的比对（注意，此时所有数据都是秘密共享形式，不允许恢复为明文进行比对）；

第三步，经过计算之后，能够得到一个比对结果数组（一个 0、1 张量的秘密共享形式，0 代表不是交集的位置，1 代表是交集的位置，不允许恢复为明文 0、1 比对数组），然后根据这个结果计算交集对应的行；

第四步，首先将两张密文表进行合并，生成完整的密文表，然后使用比对结果张量和密文表进行按行的乘法操作，即可得到基于 ID 属性的交集密文表，以方便后续 SQL 隐私查询模块的开发和使用。为了简化开发难度，其中不是交集中的数据记录，保留全 0 行（秘密共享形式）即可，不需要删除操作。

2.3 SQL 隐私查询模块开发

用户想要在这个分布式数据库的交集之上进行一些 SQL 查询，由于交集数据都是秘密共享形式，所以整个查询的中间结果在各个参与方的视角下都是秘密共享形式。具体地开发步骤可以参考如下过程：

第一步，SQL 解析步骤。用户传入一条 SELECT 查询语句（本作业只考虑 SELECT 查询），同学们可以使用 sqlparse 库或者正则匹配等方式，将 SQL 先转换成各种关键字的键值存储。当然同学们也可以根据自己的开发偏好自行选择解析形式，只要能够完成相应功能即可，如下仅提供作业设计者实现此步骤所选择的一种方式。

例如：“SELECT ID FROM TABLE WHERE AGE < 50 AND (DEPOSIT <= 10000 OR DEPOSIT > 500000)”应该可以转换成如下形式：

`Map['SELECT'] = ['ID']`

```
Map[ 'FROM' ] = [ 'TABLE' ]
```

```
Map[ 'WHERE' ] = [ 'AGE', '<', '50', 'AND', '(', 'DEPOSIT', '<=', '10000', 'OR',  
'DEPOSIT', '>', '500000' ]
```

第二步，各个关键字对应的元组解析。当一个 SELECT 被分解为键值对存储之后，就可以根据这个键值存储，解析各个关键字对应的元组。比如 ‘SELECT’ 对应的元组代表最终用户需要返回的列； ‘FROM’ 解析在本作业可以省略，因为在 PSI 步骤，最终只要求生成一张密文表，直接在此表进行查询即可； ‘WHERE’ 对应的元组代表查询条件。其中 ‘WHERE’ 解析较为复杂，在这里提供一种简单的实现方式，就是将 WHERE 对应的中缀表达式数组转为后缀表达式数组（类似于四则运算的表达式树 AST 的后缀遍历），然后依次进行计算。注意，所有的计算结果都必须保持秘密共享形式，不允许恢复为明文进行计算！而所有涉及到的隐私算子 API 调用方法和说明，请仔细参考 Rosetta 开发[说明文档](#)。

第三步，将最终的结果进行 reveal，以检验程序设计是否正确。

这里给出一个最终可能的结果，比如在 SELECT * FROM ... WHERE ... 执行完之后，程序在 reveal 明文结果之后，应该输出类似于这样的结果：

```
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'1064' b'64' b'12005064' b'9' b'581000']  
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'1067' b'20' b'12005067' b'9' b'887000']  
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'0' b'0' b'0' b'0' b'0']  
[b'1072' b'70' b'12005072' b'2' b'996000']  
[b'0' b'0' b'0' b'0' b'0']
```

图 1 结果输出样本

全 b'0' 的行代表不满足 WHERE 条件或者不在 PSI 里面的记录，其他恢复成明文的结果代表在 PSI 里面的数据且满足 WHERE 查询条件的记录。

第三部分 开发目的

本次大作业设计，旨在让同学们根据现有的安全多方计算框架开发一个现实场景中非常有实用价值的模拟 MPC 系统。目的有如下几点：

(1) 根据《数据安全》课程所学内容，理解课程中所学习过的重点内容：比如安全多

方计算（MPC）、秘密共享（SS）、隐私集合求交技术（PSI）、分布式数据库等重要概念，加深对此领域的了解；

（2）锻炼学生综合运用本科所学知识及编程能力，提升同学们对于环境配置与安装、python 语言开发、代码管理以及 MPC 框架使用的能力，这些能力在日后的项目开发、竞赛编程以及实习工作等，都有非常重要的意义和价值；

（3）加强同学们的分工协作能力，本作业需要同学们从环境配置开始，到模块开发，系统测试等，单人完成任务较重，如果多个同学一起分工明确，相信同学们可以顺利完成这次大作业的各项任务。

第四部分 提交要求和评分标准

大作业提交内容：实验报告（内容须包括但不限于：环境配置过程、模块开发过程、关键源码说明、测试截图、开发感想收获与大作业设计思辨问题等）、实验代码

大作业评分标准：

1、配置安装【20 分】：能够配置与安装 Rosetta 框架，并熟练使用其中的隐私算子接口，即可得到基础分 20 分；

2、PSI 模块开发【30 分】：在 Rosetta 框架之上，实现两方隐私集合求交，得到交集密文表，即可获得 30 分；

3、SQL 隐私查询解析与开发【50 分】：在交集密文表之上，能够实现 SELECT 语句的解析与查询，此步骤按照同学们的实现程度进行梯度给分：

（3.1）【25 分】能够实现形如 SELECT ... FROM ... WHERE 的完整查询语句，其中 WHERE 为单查询条件，比如 ‘WHERE deposit > 300000’ ；

（3.2）【15 分】能够实现复杂的查询语句，综合运用数据结构知识和安全多方计算框架开发。检查时可能要求通过的测试用例可以参考形如：


‘ SELECT ID, AGE FROM TABLE WHERE AGE < 50 AND (DEPOSIT <= 10000 OR DEPOSIT > 500000)’

（3.3）【10 分】思辨过程：请思考本次大作业设计的 PSI 方案和图 1 给出的这种输出结果，在现实中直接运用可能存在什么安全问题？能运用数据安全课程所学知识，结合安全多方计算定义和 PSI 相关知识给出合理解释。

附-满分示例：

例如给定 SQL 输入：” SELECT ID,DEPOSIT FROM TABLE WHERE DEPOSIT > 500000

AND (CREDIT < 5 OR CREDIT >= 7)”，能够输出如图 2 所示（截图仅代表参考）reveal 之后的结果，即可获得满分。



```
PROBLEMS (15) OUTPUT DEBUG CONSOLE TERMINAL
[b'0' b'0']
[b'1012' b'825000']
[b'0' b'0']
[b'1014' b'635000']
[b'0' b'0']
[b'0' b'0']
[b'1017' b'874000']
[b'0' b'0']
[b'0' b'0']
[b'0' b'0']
[b'1021' b'942000']
[b'0' b'0']
[b'1023' b'577000']
[b'1024' b'641000']
[b'0' b'0']
[b'0' b'0']
[b'0' b'0']
[b'0' b'0']
[b'0' b'0']
[b'1030' b'907000']
[b'0' b'0']
[b'0' b'0']
[b'0' b'0']
[b'0' b'0']
[b'1035' b'700000']
[b'0' b'0']
[b'1037' b'574000']
[b'0' b'0']
```

图 2