



恶意DGA域名检测系统的简单实现

2025年5月



01

什么是域名

Domain Name

● 域名




域名 (Domain Name)

——Internet中主机地址的一种表示形式，是IP地址的别名

例如：南开大学网站服务器

域名 `www.nankai.edu.cn`

IP `222.30.45.190`



● 域名



域名的结构



- 域名采用的是层次树状结构的命名方法
- 域名结构由若干分量组成，各分量之间用“.”分隔，各分量代表不同级别的

的域名


www . nankai . edu . cn
..... . 三级域名 . 二级域名 . 顶级域名

SLD TLD

xb . nankai . edu . cn
cyber . nankai . edu . cn

DGA域名

- 使用域名生成算法（Domain Generation Algorithms, DGA）产生的伪随机域名
- 协助僵尸网络中被控主机与C&C服务器通信



DGA域名的特点

- 绝大部分域名为未注册域名
- 具有伪随机性，与正常域名有一定差别
- 可能使用不常用的顶级域名

常见的顶级域名

.com/.net/.org /.edu/.gov/.int /.....

国家地区域名：.cn/.tw/.au/.ru/.jp/.....

常见DGA家族及实例

DGA	生成方式	实例
Conficker	以世界时间为随机种子的生成器	fabdpdri sfqzqigzs
Kraken	长度为[6-10]的随机字符串	rhxqccwdhwg huwoyvagozu
Srizbi	基于异或操作的时间转换器	wqpyygsq tqdaourf
Torpig	以当前时间和“8”为随机种子的生成器	16ah4a9ax0apra 12ah4a6abx5apra
kwyjibo	基于隐马尔可夫模型生成的英文字符串	overloadable refillingman



02

特征工程

Feature Engineering

●特征工程



“数据和特征决定机器学习的上线，而模型和算法只是逼近这个上限而已。”

原始数据

msspsoft.com	0
miningnews.net	0
amjyielrtm7qtuxx3190cew7.org	1
ombrelo.com.br	0
81ac56474d277.hosting	1
ayudalinux.com	0
capnny.com	1
isettravel.com	0
yknpsujchwhqwmmr.tv	1
lizcooktattoo.com	0
shareist.com	0
lockerbleibenonline.de	0
musicsearchcenter.com	0
e61ftn2613ky170w.cn	1
newmediacampaigns.com	0
bg9gmt1l2k88t9ecihf1t4gmq5.net	1
dns29parks.in	0
vsfjzrwjhwhjkrs.org	1
gjrzyihtca.org	1
smmhnn.com	1
illumina.com	0
24jobs.com.mm	0

DGA域名来源：360、Bambenek等情报源

正常域名来源：Alexa最受欢迎域名数据



一、结构特征

d1 = baidu.com

d2 = 159vthg1nqmpuyh6.beauty

#	特征	取值类型	d1	d2
1	域名总长度	整数	9	23
2	二级域名长度	整数	5	16
3	顶级域名长度	整数	3	6
4	是否使用某些被滥用的顶级域名	布尔	0	1
5				

.live/.degree/.hair/.makeup/.haus/.beauty/.gq/.market/.fyi/.top



<https://www.spamhaus.org/statistics/tlds/>



二、语言特征

d1 = baidu.com

d2 = 159vthg1nqmpuyh6.beauty

#	特征	取值类型	d1	d2
1	域名字符总数（去重）	整数	8	17
2	二级域名字符总数（去重）	整数	5	14
3	顶级域名字符总数（去重）	整数	3	6
4	二级域名数字总数	整数	0	5
5	二级域名数字占比	实数	0.0	0.31
6	二级域名特殊字符占比	实数	0.0	0.0
7	二级域名十六进制字符占比	实数	0.6	0.31

特殊字符：“-” 和 “_”



●二、语言特征

d1 = baidu.com

d2 = 159vthg1nqmpuyh6. beauty

#	特征	取值类型	d1	d2
8	二级域名元音字母占比	实数	0.6	0.06
9	二级域名辅音字符占比	实数	0.4	0.63
10	二级域名重复字符/字符总数（去重）	实数	0.0	0.14
11	二级域名连续辅音占比	实数	0.0	0.63
12	二级域名连续数字占比	实数	0.0	0.19
13	二级域名Gib成文检测	布尔	1	0



三、统计特征（拓展）

d1 = baidu.com

d2 = 159vthg1nqmpuyh6. beauty

#	特征	取值类型	d1	d2
1	香农熵	实数	2.32	3.45
2	2元字符出现频次的中位数	整数	4.38	3.32
3	3元字符出现频次的中位数	整数	3.17	1.56
4				



03


分类算法

Classification

● 传统机器学习算法之KNN

K近邻算法 (KNN, K-Nearest Neighbor)

取待测样本在特征空间中最邻近的K个已知样本，如果这K个已知样本大部分都属于某一类型，那么待测样本可以判定为该类型。



● 传统机器学习算法之KNN

K近邻算法 (KNN, K-Nearest Neighbor)

取待测样本在特征空间中**最邻近**的K个已知样本，如果这K个已知样本大部分都属于某一类型，那么待测样本可以判定为该类型。

距离度
量方式

欧氏距离 (Euclidean Distance)

$$D(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

曼哈顿距离 (Manhattan Distance)

$$D(x, y) = \sum_{i=1}^k |x_i - y_i|$$

切比雪夫距离 (Chebyshev Distance)


$$D(x, y) = \max_i (|x_i - y_i|)$$

.....

● 传统机器学习算法之SVM

支持向量机 (SVM, Support Vector Machines)

对已知样本进行求解得到特征空间中的最大间隔超平面，作为分类边界。



● 如何评估模型好坏?

混淆矩阵

	实际正例	实际负例
预测正例	TP (True Positives)	FP (False Positives)
预测负例	FN (False Negatives)	TN (True Negatives)

$$\text{准确率 } Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{召回率 } Recall = \frac{TP}{TP + FN}$$

$$\text{精确度 } Precision = \frac{TP}{TP + FP}$$

$$\text{F1值 } F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$



04

实验要求

Experiment

● 实验内容

1. 理解代码结构，配置环境（10分）
2. 补充feature_extraction.py文件（30分）
3. 补充detection.py文件（30分）
4. 简单可视化（20分）
5. 扩展实验（10分）

其他要求详见实验文档



恶意域名检测

一个基于可信度模型的恶意域名检测系统

请输入待测域名

检测

样本库总量

520,618,714

恶意样本数

205,016,624

良性样本数

315,602,090

域名样本库中包含了良性样本（正常域名）和恶意样本（恶意域名）两类数据，其中良性样本，采集自Alexa和Tranco_K26W-1m两个常用白名单列表，恶意样本相比于良性样本，获取过程更加复杂和困难，因此本系统使用网络爬虫技术收集国内外安全公司授权提供的威胁情报以及一些安全项目开源的威胁情报作为恶意样本数据，如360netlab、cybercrime-tracker等，本检测系统在该样本库的基础上训练得到。

下图是每日收集的恶意域名数量统计图：



域名检测失败

检测域名为：**nankai。**

域名格式不正确，域名中只能包含下划线、短横线、点、字母、数字，请输入正确域名！！

[返回](#)

© 2021 Copyright: 南开大学反病毒实验室 (NKAMG)

域名检测成功

检测域名为: **nankai.edu.cn**

✓ 安全

检测子模型	检测结果	恶意概率	p值 (可信度)
KNN	0	0.0000	1.0
SVM	0	0.0000	1.0
LR	0	0.0186	0.8833
DT	0	0.0316	0.9719
RF	0	0.0000	1.0
ADABoost	0	0.4857	0.7912
GBDT	0	0.0002	0.9844
XGBoost	0	0.0018	0.9931
LSTM	0	0.0351	0.2922

返回

域名检测成功

检测域名为: 159vthg1nqmpuyh6.viajes

⊗ 危险

检测子模型	检测结果	恶意概率	p值 (可信度)
KNN	1	1.0000	1.0
SVM	1	1.0000	1.0
LR	1	1.0000	0.7248
DT	1	0.9775	0.9901
RF	1	1.0000	1.0
ADABOOST	1	0.5290	0.6999
GBDT	1	0.9997	0.647
XGBoost	1	0.9995	0.7511
LSTM	1	1.0000	0.6278

返回



谢谢！

